

深度強化學習 HW2 : Cliff Walking 實驗報告

一、作業目的

本作業旨在實作並比較兩種經典強化學習演算法——Q-learning 與 SARSA。透過相同環境與參數設定，分析其學習行為、收斂特性以及最終策略差異。

二、環境描述

本實驗採用經典的格子世界（Gridworld）問題，亦稱為「Cliff Walking」環境。環境設定如下：

- 使用一個矩形網格（ 4×12 ）
- 起點（Start）位於左下角
- 終點（Goal）位於右下角
- 起點與終點之間的底部區域為「懸崖（Cliff）」

當代理（agent）進入懸崖時，會受到重大懲罰並回到起點。

三、問題設定

- 狀態空間（State Space）：所有網格位置（共 48 個狀態）。
- 動作空間（Action Space）：上、下、左、右。
- 獎勵機制（Reward）：
 - 每移動一步： -1
 - 掉入懸崖： -100 ，並回到起點
 - 到達終點：回合結束
- 策略（Policy）： ϵ -greedy（本基礎實驗設定 $\epsilon = 0.1$ ）。
- 學習率（ α ）： 0.1
- 折扣因子（ γ ）： 0.9
- 訓練回合數（Episodes）： 1000 回合（符合至少 500 回合之要求，並以 20 次獨立隨機種子取平均，以確保數據客觀性）。

四、作業內容

（一）演算法實作

本專案分別實作了以下兩種演算法，兩者皆建立並持續更新狀態-動作價值函數 $Q(s, a)$ ：

- Q-learning（離策略方法，Off-policy）：使用下一狀態的最大 Q 值來更新當前狀態的 Q 值。
- SARSA（同策略方法，On-policy）：使用下一狀態實際依據 ϵ -greedy 採取的動作之 Q 值來更新。

（二）訓練過程

在相同的環境與參數設定下，使用 ϵ -greedy 策略進行訓練。為確保兩種方法的公平

比較，實驗中我們使用相同的隨機種子（20 Seeds）獨立訓練兩種代理人各 1000 回合，以消除單一執行的隨機誤差。

（三）結果分析

1. 學習表現

- 繪製每一回合的累積獎勵（**Total Reward**）曲線：![學習曲線](file:///C:/Users/donuop/Documents/grassland/DRL_HW2_Cliff_Walking/results/figures/01_learning_curves.png) 圖說：*Q-learning* 與 *SARSA* 在 1000 回合中的平滑累積獎勵（20 seeds 平均）。
- 比較收斂速度：![收斂速度](file:///C:/Users/donuop/Documents/grassland/DRL_HW2_Cliff_Walking/results/figures/02_convergence.png) 實驗結果顯示，**SARSA** 的收斂速度顯著快於 **Q-Learning**。*SARSA* 約在 200 回合後即穩定上升並收斂在平均獎勵約 \$-20\$ 的水準；反觀 *Q-Learning*，在整個 1000 回合中都在 \$-40\$ 至 \$-60\$ 之間劇烈震盪，由於頻繁掉入懸崖，在給定的平滑閾值下遲遲未能達到穩定收斂。

2. 策略行為

- 視覺化最終學習到的路徑：**Q-Learning** 最終貪婪策略：![Q-Learning Policy](file:///C:/Users/donuop/Documents/grassland/DRL_HW2_Cliff_Walking/results/figures/04_policy_qlearning.png) **SARSA** 最終貪婪策略：![SARSA Policy](file:///C:/Users/donuop/Documents/grassland/DRL_HW2_Cliff_Walking/results/figures/04_policy_sarsa.png) 圖說：箭頭代表各狀態下 *Q* 值最大的動作，藍色虛線為從起點出發依貪婪策略行走之真實軌跡。
- 分析是否傾向冒險或保守：
 - **Q-learning** 傾向冒險：其學到的最終路徑緊貼著懸崖邊緣（最短路徑）。雖然理論上這是最佳解（只需 13 步），但在探索機制（ $\epsilon = 0.1$ ）下，只要有 10% 的機率隨機選擇動作，就極容易掉入懸崖。
 - **SARSA** 傾向保守：其學到的路徑遠離懸崖，選擇繞行網格的最上方。雖然路徑較長，但徹底避開了因探索而掉入懸崖的巨大風險。

3. 穩定性分析

- 比較學習過程中的波動程度：![穩定性分析](file:///C:/Users/donuop/Documents/grassland/DRL_HW2_Cliff_Walking/results/figures/06_stability.png) 從波動程度圖可見，*SARSA* 在學習初期的波動迅速下降，並維持在極低的水準（跨種子的最終標準差約 2.37）。相反地，*Q-learning* 的波動程度始終居高不下（標準差達 6.56），表現極不穩定。
- 討論探索（**exploration**）對結果的影響： ϵ -greedy 的探索機制是造成兩者穩定性差異的主因。*Q-learning* 更新時不考慮探索風險（永遠樂觀假設未來會走最佳步），導致其在實際包含探索的訓練過程中不斷掉入懸崖承受 \$-100\$ 的懲罰。*SARSA* 則將探索的隨機性直接納入 *Q* 值的更新計算中，因此自然地學會了避開高風險區域。我們透過以下的 ϵ 敏感度分析圖也證實，當 ϵ 越高（探索越多），*Q-learning* 的表現退化越嚴重，而 *SARSA* 則能保持相對的穩定。![Epsilon 敏感度](file:///C:/Users/donuop/Documents/grassland/DRL_HW2_Cliff_Walking/results/figures/05_epsilon_sensitivity.png)

五、理論比較與討論

在報告中，我們說明以下概念：

- **Q-learning** 為離策略（**Off-policy**）方法，其更新基於「下一狀態的最佳可能行動」（ $\max_a Q(s', a)$ ），即使該行動並未被實際執行。因此，Q-learning 傾向學習到理論上的最優策略（最短路徑），但在實際訓練過程中因為沒有將探索風險考慮進去，導致實際表現承受較高風險。
- **SARSA** 為同策略（**On-policy**）方法，其更新基於「實際採取的行動」（ $Q(s', a')$ ），因此會反映探索策略的影響。這使得 SARSA 在學習過程中會主動考量到隨機掉下懸崖的風險，進而傾向學習到在實際探索策略下較安全、穩定的行為（繞遠路）。

六、結論要求

總結兩種方法在本實驗中的差異：

- 哪一種方法收斂較快：**SARSA** 收斂較快。因為其價值估計包含了探索懲罰，能迅速將懸崖周邊標記為低價值並穩定在安全路徑上。
- 哪一種方法較穩定：**SARSA** 較穩定。它學會了避開懸崖，因而在 ϵ -greedy 執行下能持續獲得平穩的獎勵，回合間的波動極小。
- 在何種情境下應選擇 **Q-learning** 或 **SARSA**：
 - 選擇 **SARSA**：當「訓練階段的成本或安全性」非常重要時（例如實體機器人訓練、自駕車等不容許嚴重失誤的場景），或者系統在部署上線後仍需保持一定的探索率（持續學習）時，SARSA 是更好的選擇，因為它能保證過程的安全與穩定。
 - 選擇 **Q-learning**：當訓練環境是低成本、絕對安全的模擬器，且最終部署時會將探索率關閉（ $\epsilon = 0$ ），純粹以完全貪婪（Greedy）的策略執行以追求極致的效能與最短路徑最佳解時，應選擇 Q-learning。